# 无 CPU 双 SRAM NPU：INT8 / INT4 后仿报告

测试快照：exp/no_cpu @ fea96a2；no_cpu_INT4 @ 02185d8 + 兼容修正 | 2026-10-31 至 2026-11-02

## 结论

两版均完成 Genus 映射综合、含 PAD 环的完整 PnR、9 项 Innovus 检查与有效 SDF 最大延迟门级后仿。INT4 减少逻辑面积，但两颗 SRAM 的物理面积不变。

**2 / 2**
课程级实现与 SDF 门级后仿通过

**−15.41%**
INT4 综合标准单元面积相对 INT8

**+0.612 ns**
INT4 setup 余量 hold +0.020 ns

**70 / 64**
INT8 / INT4 JTAG 命令全通过

| 指标 | INT8 | INT4 |
| --- | --- | --- |
| 综合标准单元面积 | 1.315184 mm2 | 1.112578 mm2 |
| 双 SRAM 宏面积 / 数量 | 0.802887 mm2 / 2 | 0.802887 mm2 / 2 |
| 综合单元 + 宏总面积 | 2.118071 mm2 | 1.915465 mm2 |
| Die（含 PAD 环） | 1940.40 um 见方 / 3.765152 mm2 | 1920.24 um 见方 / 3.687322 mm2 |
| Core 面积 | 2.690387 mm2 | 2.624659 mm2 |
| Setup / Hold WNS | +0.457 / +0.020 ns | +0.612 / +0.020 ns |
| Setup / Hold TNS | 0 / 0 ns | 0 / 0 ns |
| Innovus DRC / 天线 | 0 / 0 | 0 / 0 |
| SDF 结果 / JTAG 命令 | PASS / 70 条 | PASS / 64 条 |

范围：仅 TT / 1.8 V / 25° C，核心 50 MHz、JTAG 1 MHz。没有执行独立 Calibre、PrimeTime、Formality 或多角 STA、IR/EM；不构成流片签核。每版一个受控布局点，没有重新搜索或独立重复。

## 源码归属与时效

报告仅覆盖上述冻结快照。2026-11-02 发布时，远端 exp/no_cpu 已前进至 175484e，新增 ASIC mailbox CDC 约束与门禁；该后续提交未在本轮重跑，不能沿用本报告判为通过。旧流程的 9 项检查不包含该新增 CDC 审计。

# 实现基线与执行过程

同一 4×8 阵列、双 SRAM 和课程工具链；数值格式与模型 ABI 不同

## 两版实现边界

| 项目 | INT8 | INT4 |
| --- | --- | --- |
| 激活 / 权重 | signed INT8，1 元素 / byte | signed INT4，2 元素 / byte，低 nibble 在先 |
| 累积 / 量化 | 26-bit K 组累积；Q31 | 18-bit K 组累积；Q15 |
| Bias / 原始张量 | INT32 | INT32，保留原有溢出语义 |
| 模型 ABI | 2.1 / 0x00020001 | 3.0 / 0x00030000 |
| 存储 | 模型 8 KiB + 激活 8 KiB | 容量与宏不变；激活可容纳 16384 个 INT4 |
| 调试配置 | ASIC 关闭波形与逐算子摘要 | 同左；全局性能计数器保留 |
| 算子 | Conv、FC、MaxPool、ReLU、Requant | 同左，保留合法融合、背压和恢复 |

## 运行链路与前测

1. 冻结源码与输入哈希
2. 真实 SRAM 宏 RTL / JTAG 前测
3. Genus → Innovus：放置 / CTS / 布线 / 物理验收
4. 导出网表 / 寄生 / SDF → Xcelium 门级后仿

工具：Genus 19.17-s144_1、Innovus 21.16-s078_1、Xcelium 21.09-s013。前测通过物理 TAP 装载非零数据、执行两次推理并检查 IRQ 与复位恢复。零延迟 RTL 前测关闭模型时序检查；正式 SDF 后仿保留严格检查。

## INT4 两项修正：均保留原失败证据

| 问题 | 修正与范围 |
| --- | --- |
| Xcelium 拒绝声明顺序 | npu_activation_store.sv 中 sram_q 移到首次引用前；没有改变表达式或计算逻辑。 |
| 复位 ABI 预期残留旧值 | tb_fullchip.sv：0x20001 → 0x30000，仅修测试台；64 条命令与复位恢复重跑通过。 |

INT8 无本轮 RTL 补丁。INT4 原始源码包与两项修正的文件哈希分别归档；未把测试台错误当作硬件功能失败，也未修改黄金输出来迎合结果。

# 面积、资源与物理归属

面积口径分开报告：综合库面积、布线后活动单元、Core 与 Die

## 综合标准单元面积（不含 SRAM）




| 资源 / 几何 | INT8 | INT4 | 变化 |
|---|---|---|---|
| 综合标准单元 + 宏 | 2.118071 mm2 | 1.915465 mm2 | -9.57% |
| 布线后活动标准单元 | 1.335700 mm2 | 1.130344 mm2 | -15.37% |
| 活动标准单元实例 | 55,340 | 49,730 | -10.14% |
| SRAM 宏 | 0.802887 mm2 | 0.802887 mm2 | 不变 |
| Core 面积 | 2.690387 mm2 | 2.624659 mm2 | -2.44% |
| Die 面积 | 3.765152 mm2 | 3.687322 mm2 | -2.07% |
| CTS/修复活动面积净增 | 0.008785 mm2 | 0.007244 mm2 | 非全部 CTS 单元面积 |

## 综合层级（库面积；父子不可重复相加）

| 层级 | INT8 面积 / 单元数 | INT4 面积 / 单元数 |
|---|---|---|
| my_soc_top（含宏） | 2.118071 mm2 / 53,358 | 1.915465 mm2 / 48,149 |
| i_control_i_npu | 1.073808 mm2 / 40,786 | 0.853819 mm2 / 33,881 |
| NPU / i_requant | 0.063749 mm2 / 2,924 | 0.040289 mm2 / 2,034 |
| NPU / i_array | 综合已展平，未独立报告 | 0.085244 mm2 / 3,570 |
| i_control_i_activation | 综合已展平，未独立报告 | 0.580960 mm2 / 10,818（含宏） |

标准单元面积下降 15.41%，不代表 Die 同比缩小：两个宏尺寸及 halo 不变，西侧叠放形成几何下限。两版不是面积搜索的全局最优解，也不证明 INT4 分类精度或端到端性能提升。

来源：synthesis/area.json、area.rpt；candidate/result.json、final_cells.tsv。活动标准单元排除 IO、filler、tap、decap、天线单元；CTS/修复净增以 pre-CTS 与最终活动面积差计算。命名分组及无法精确归属的残差保存于 area_groups.json。

# 时序、拥塞与物理检查

约束：20 ns core / 1000 ns JTAG，2 ns I/O，0.2 ns uncertainty；不降低目标频率

## 布线后 Setup WNS




| 指标 | INT8 | INT4 |
| --- | --- | --- |
| Setup WNS / TNS | +0.457 / 0 ns | +0.612 / 0 ns |
| Hold WNS / TNS | +0.020 / 0 ns | +0.020 / 0 ns |
| 走线中心线总长（不含特殊网） | 3.7252 m | 3.1604 m（−15.16%） |
| 全局估计布线 usage H / V | 21.3% / 23.8% | 17.9% / 21.5% |
| 全局 overflow H / V | 0.36% / 0.20% | 0.21% / 0.13% |
| 布局点 | u70 / west_stack / congestion | u70 / west_stack / congestion |
| 宏 halo / 工艺布线层 | 26 um / METAL2-6 | 同左 |

## 9 项物理验收全部通过

| 检查 | INT8 | INT4 |
| --- | --- | --- |
| Innovus 几何 DRC / process antenna | 0 / 0 | 0 / 0 |
| 电源 DRC / 电源连通 | PASS / PASS | PASS / PASS |
| 信号连通 / DRV | PASS / PASS | PASS / PASS |
| 放置合法 / PAD 几何 / 端口 | PASS / PASS / PASS | PASS / PASS / PASS |

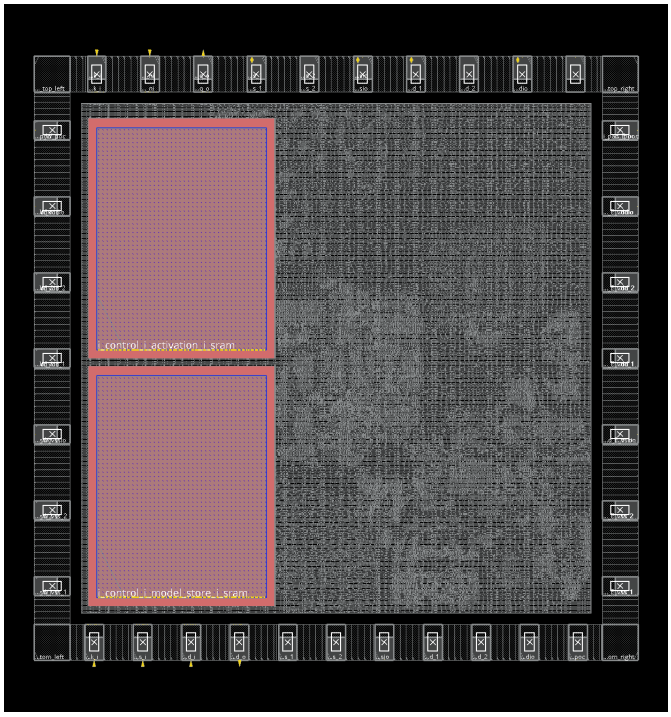
全局 overflow 是拥塞估计，不能等同于详细布线 DRC；usage 也不能当作标准单元利用率。布局脚本目标 70% 与扣除宏及 halo 后的工具密度不是同一分母。IO 原生拼接电源轨的既有信息按脚本单独处理。

## 保留的诊断与约束边界

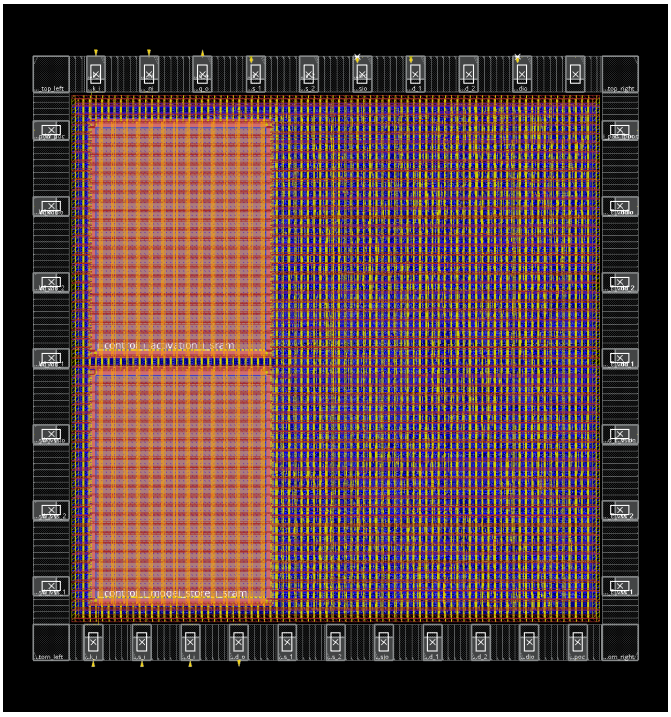
Innovus 各出现两次 IMPSP-9099 扫描链诊断：INT8 16.54%、INT4 15.62% 的触发器未定义完整扫描链。工具正常退出且实现检查通过，但 DFT 未完成。上述时序只适用于本轮冻结约束；不声明新增 scoped CDC 门禁已通过，也不构成 CDC 协议或亚稳态证明。

# INT8 最终版图（Innovus 实际渲染）

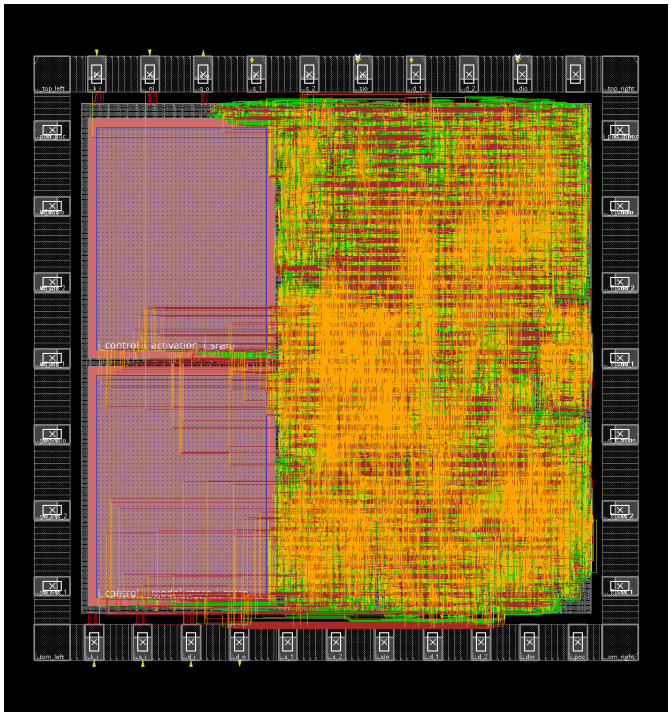
从各自最终数据库副本读取；不复用旧版本截图，不保存或修改验收数据库



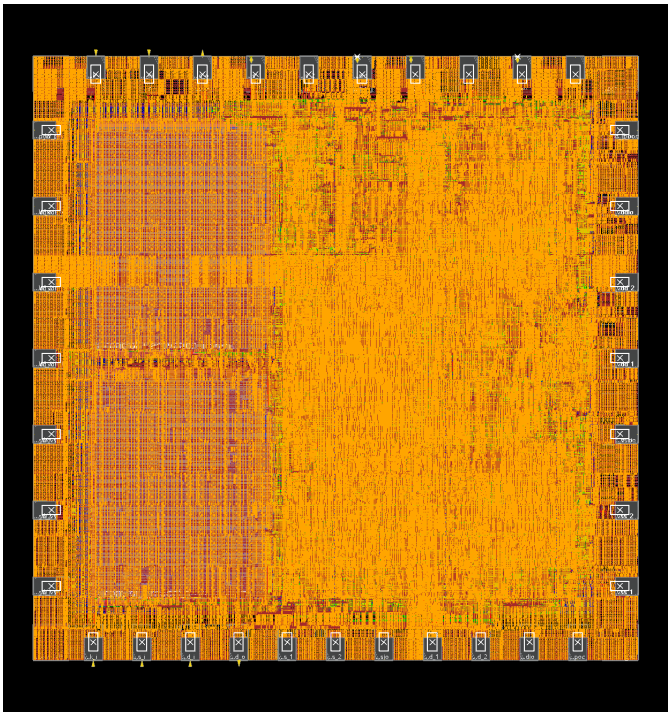
器件摆放：双 SRAM、西侧叠放、PAD 环



电源：Core / SRAM 环及条带



信号布线：不含金属填充

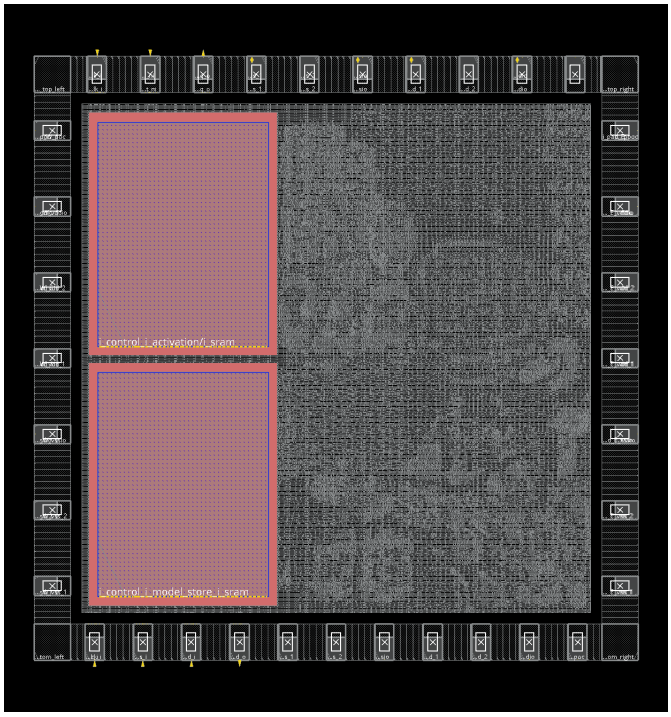


全部图层：包含最终金属填充

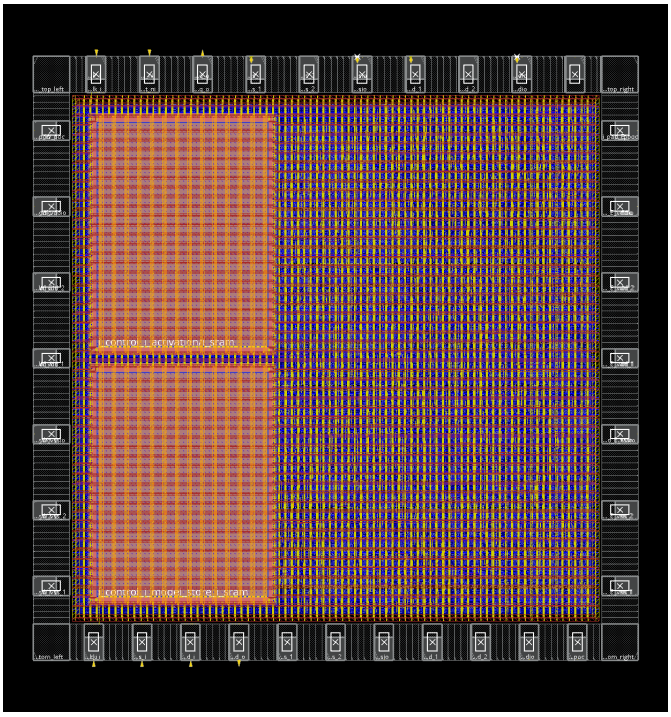
图示来源：report_shots_int8；final.enc.dat 只读副本。PAD 打线开口与电气 PAD 的设计叠接不按普通单元重叠判错。截图仅辅助观察，数值验收来自同一最终数据库导出的报告。

# INT4 最终版图（Innovus 实际渲染）

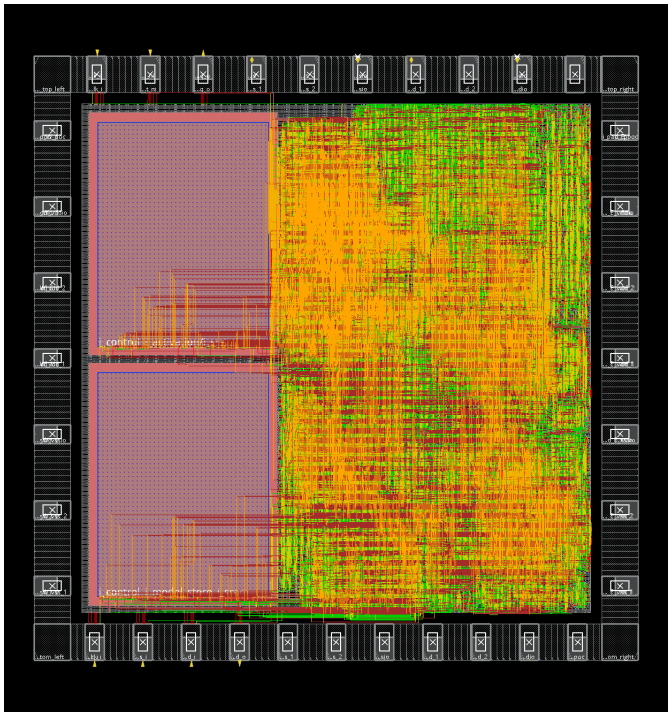
从各自最终数据库副本读取；不复用旧版本截图，不保存或修改验收数据库



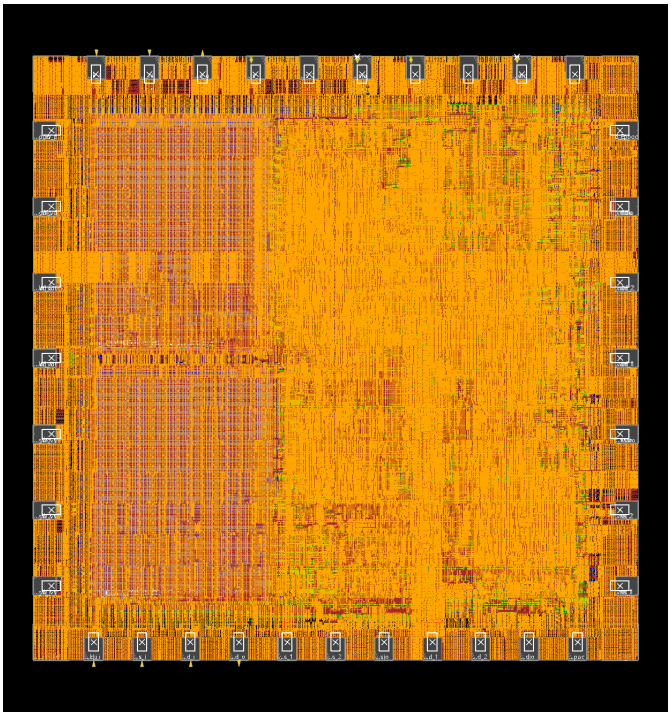
器件摆放：双 SRAM、西侧叠放、PAD 环



电源：Core / SRAM 环及条带



信号布线：不含金属填充



全部图层：包含最终金属填充

图示来源：report_shots_int4；final.enc.dat 只读副本。PAD 打线开口与电气 PAD 的设计叠接不按普通单元重叠判错。截图仅辅助观察，数值验收来自同一最终数据库导出的报告。

# SDF 判定、交付文件与证据索引

有效延迟标注的代表性门级测试；覆盖范围与告警逐项说明

## 门级后仿实际结果

| 检查 | INT8 | INT4 |
| --- | --- | --- |
| 编译期 SDF 标注 / 最终判定 | 存在 / PASS | 存在 / PASS |
| 物理 JTAG 命令 | 70 / 70 | 64 / 64 |
| 两次推理、结果比对、IRQ、复位 | 通过 | 通过 |
| 意外 SDF 告警 / 时序违例 | 0 / 0 | 0 / 0 |
| 已分类 ifnone 记录数 | 65,850 | 41,736 |
| 已分类 SRAM negedge PERIOD 记录 | 6 | 6 |
| 第 0 时刻输入 PAD 初始化冲突 | 5 | 5 |

使用 xrun -sdf_cmd_file，在 elaboration 阶段标注 MAXIMUM 延迟，保留 +define+NTC、+define+RECREM、+neg_tchk 与完整告警日志。SRAM CLK→Q 只去掉不匹配的沿限定，保留延迟值。只对精确列举的 6 个异步 CDC 采样触发器关闭时序检查，其余保持开启。ifnone 默认弧与宏模型仅检查上升沿周期的差异沿用旧流程分类。告警条数是完整日志审计的记录数，不是独立失效点数。

这不是完整 74 / 82 项 RTL 回归的逐项门级重跑；有限的两次推理和恢复测试不能替代穷尽验证。单一 TT 角测试不证明所有电压、温度与频率条件均通过。

## 导出、复现与证据

| 内容 | 可追溯位置 |
| --- | --- |
| 导出已生成且非空 | simulation.v、physical.v、mapped.sdc、routed.def、routed.sdf.gz、routed.spef.gz、chip.lef、chip.gds.gz |
| 服务器根目录 | /home/s2400012724/chip-fullstack-2026/<br>postlayout_latest_20261031 |
| INT8 / INT4 最终候选 | int8_run/candidates/course<br>int4_run_abi3/candidates/course |
| 仓库公开证据 | docs/validation/int8_int4_postlayout_20261102/<br>comparison.json、final_evidence.tar.gz、两项 patch.json |
| 复核入口 | result.json、checks.json、sdf/result.json、artifact_sha256.json；synthesis/area.rpt；final_cells.tsv |

未执行：独立 Calibre DRC/LVS/PEX、PrimeTime、Formality、多角 STA、IR/EM、DFT/ATPG、封装/ESD 与流片签核。私有 PDK、宏模型、完整网表和数据库留在服务器，公开归档仅含结果报告、哈希、面积坐标与补丁记录。